心脏超声影像 HOCM 二分类项目总结

一、项目目标

利用多模态 Embedding 模型对心脏超声影像（视频 + 静态图）进行特征编码，在此基础上训练一个二分类全连接网络，区分 **HOCM 玛法凯泰阳性** 与 **体检阴性** 两类样本。

二、数据概况

2.1 数据来源

```
视频编码器/
├── HOCM玛法凯泰 影像/        ← 阳性 (label=1)
│   └── 患者名-日期-编号/
│       ├── 二腔.mp4 / .avi
│       ├── 三腔.mp4 / .avi
│       ├── 四腔.mp4 / .avi
│       ├── LV-GLS.jpg
│       └── RV-GLS.jpg
└── 体检中心影像/             ← 阴性 (label=0)
    └── ...（同上结构）
```

2.2 数据统计

类别	样本数
HOCM 阳性	295
体检阴性	85
总计	**380**

媒体类型	数量
视频 (.mp4/.avi)	219
图片 (.jpg)	161

2.3 切面类型与文字描述

从 `文字表述.txt` 加载 5 类切面的医学描述，与视觉文件一一匹配：

文件名匹配	文字描述
二腔	这是放大的左室心尖二腔心切面的动态图
三腔	这是放大的左室心尖三腔心切面的动态图
四腔	这是放大的左室心尖四腔心切面的动态图
LV-GLS	这是左室心肌纵向应变图
RV-GLS	这是右室心肌纵向应变图

三、编码器模型

3.1 选用模型

项目	详情
模型名称	`multimodal-embedding-v1` / `qwen3-vl-embedding`
调用方式	阿里云 DashScope HTTP API
Endpoint	`https://dashscope.aliyuncs.com/api/v1/services/embeddings/multimodal-embedding/multimodal-embedding`
输出维度	1024 / 2560

3.2 视频输入方式：base64 Data URI 编码

DashScope API 通过 HTTP JSON 协议通信，不能直接传输二进制视频文件。所有视频和图片均通过 **base64 Data URI** 方式嵌入 JSON 请求体中：

```
本地视频 (二进制字节)
    ↓ base64 编码（每3字节→4个ASCII字符，体积膨胀约33%）
    ↓ 添加 MIME 前缀
"data:video/mp4;base64,AAAAIGZ0eHB..."
    ↓ 放入 JSON
{
  "model": "qwen3-vl-embedding",
  "input": {
    "contents": [
      {"video": "data:video/mp4;base64,AAAA..."},
      {"text": "这是放大的左室心尖二腔心切面的动态图"}
    ]
  }
}
    ↓ HTTP POST → API 解码还原视频 → 编码器提取特征
```

API 根据 JSON key（`"video"` / `"image"`）和 Data URI 的 MIME 前缀区分输入类型：

- `"video"` + `data:video/mp4;base64,...` → 视频编码（抽帧 + 时序建模）
- `"image"` + `...` → 图片编码（单帧空间编码）

限制：base64 编码后数据膨胀 33%。API 后端 Jackson JSON 解析器对单个字符串有 28MB 硬限制，对应原始视频安全阈值为 **约 21MB**。超过此大小的视频需预处理。

3.3 视频预处理策略对比

实验了两种策略：

	部分直传	全部压缩
策略	≤10MB/13MB 视频直传 base64，超限才压缩	所有视频统一 ffmpeg 压缩
压缩比例	69%~85%	100%
输入一致性	⚠️ 高（直传视频分辨率和码率各异）	✅ 极好（统一为 256px+2fps+100kbps）
时序信息	✅ 直传保留完整，压缩的部分保留	✅ 全部保留
适用维度	1024维	**2560维**

压缩原理：ffmpeg 重新编码，将任意视频统一为 `256px + 2fps + 100kbps`，文件从 15-22MB 压缩到约 48KB。输入一致性消除了视频间的域差异（格式/分辨率/帧率/码率），让编码器更聚焦于病理特征。

结论：2560 维编码器在全部压缩下 F1 达到 96.49%，比部分直传方案提升 1.66 个百分点。

四、二分类器结构

4.1 网络架构

```
输入: 1024 维 Embedding
  ↓
Linear(1024 → 512) + BatchNorm1d + ReLU + Dropout(0.3)
  ↓
Linear(512 → 128)  + BatchNorm1d + ReLU + Dropout(0.3)
  ↓
Linear(128 → 2)
  ↓
输出: 2 类 logits (阴性/阳性)
```

- **可训练参数**：592,002
- **Embedding 编码器**：冻结，不参与训练

4.2 训练配置

参数	值
优化器	AdamW
学习率	1e-3（ReduceLROnPlateau，factor=0.5，patience=5）
损失函数	**CrossEntropyLoss**
权重衰减	1e-4
Batch Size	16
最大 Epoch	50
Early Stopping	patience=10
训练/验证划分	80% / 20%（随机，seed=42）
设备	CUDA

4.3 训练流程

```
Step 1: 遍历文件夹收集样本 + 匹配文字描述
  ↓
Step 2: 调用 DashScope API 逐个提取 1024 维 Embedding → 缓存为 embeddings_cache.pt
  ↓
Step 3: 加载缓存 Embedding → 训练二分类全连接网络 → 保存 classifier_head.pt
```

五、结果分析

5.1 最终验证集指标（v2.5，最佳）

指标	值
Accuracy	**94.67%**
Precision	94.83%
Recall	98.21%
F1 Score	**96.49%**
AUC	**97.09%**
Best Val Loss	0.1674
最佳 Epoch	41

5.2 混淆矩阵（v2.5）

	预测阴性	预测阳性
实际阴性	16	3
实际阳性	1	55

5.3 核心三版本对比：v1.1 vs v2.4 vs v2.5

三个版本均使用相同的视频处理管道，仅编码器模型和维度不同：

	v1.1	v2.4	v2.5
编码器	mm-v1	qwen3-vl	qwen3-vl
维度	1024	2560	2560
视频策略	全量压缩	13MB直传+压缩	**全量压缩**
压缩比例	100%	69%	**100%**
直传比例	0%	31%	0%
样本数	375	375	375
Accuracy	92.00%	92.00%	**94.67%**
Precision	91.67%	91.67%	**94.83%**
Recall	98.21%	98.21%	98.21%
F1	94.83%	94.83%	**96.49%**
AUC	**97.93%**	96.71%	97.09%
val_loss	0.1790	0.2086	**0.1674**

> 视频总数 216。各版本压缩阈值下：10MB→15%不压缩/85%压缩；13MB→31%不压缩/69%压缩；全压缩→0%不压缩/100%压缩。

5.4 混淆矩阵对比

v1.1			**v2.4**			**v2.5**		
	预阴	预阳		预阴	预阳		预阴	预阳
实阴	11	8	实阴	14	5	实阴	16	3
实阳	1	55	实阳	1	55	实阳	1	55

5.5 对比分析

对比一：v1.1 vs v2.5（均为全压缩，仅编码器不同）

	v1.1	v2.5
编码器	mm-v1 (1024维)	qwen3-vl (2560维)
压缩比例	100%	100%
Accuracy	92.00%	**94.67%**
F1	94.83%	**96.49%**
假阳性	8	**3**

结论：同为全压缩策略下，2560 维编码器全面优于 1024 维。更高维度能更好地编码压缩视频中保留的宏观运动特征，同时假阳性从 8 降至 3，精确率从 91.67% 提升到 94.83%。

对比二：v2.4 vs v2.5（同编码器，仅策略不同）

	v2.4	v2.5
编码器	qwen3-vl (2560维)	qwen3-vl (2560维)
压缩比例	69%	**100%**
直传比例	31%	0%
Accuracy	92.00%	**94.67%**
F1	94.83%	**96.49%**
假阳性	5	**3**
AUC	96.71%	**97.09%**

结论：同为 2560 维编码器，v2.5 将 31% 的直传视频改为压缩后，F1 提升了 1.66 个百分点，假阳性减少了 2 例。这直接证明了输入一致性对高维编码器的正向贡献——统一的压缩输入消除了视频间的域差异，让模型更聚焦于病理特征。

总结

维度 × 策略的交互效应：

	全压缩	部分直传
1024维	v1.1: F1 94.83%	v1.0: F1 95.08%
2560维	**v2.5: F1 96.49%**	v2.4: F1 94.83%

- 1024 维：全压缩反而略差，低维度容量不足以弥补画质损失
- 2560 维：全压缩大幅领先，高维度能充分消化统一压缩带来的域一致性收益
- **v2.5（2560维+全压缩）综合最优**：Accuracy 94.67%、F1 96.49%、仅 3 例假阳性

六、文件清单

文件	说明
`embedding_api.py`	DashScope API 调用封装，支持 multimodal-embedding-v1
`classifier_model.py`	可训练二分类全连接层定义
`dataset.py`	数据收集、文字描述匹配、Embedding 缓存、DataLoader
`train.py`	训练主脚本（collect / precompute / train 三阶段）
`infer.py`	推理脚本，支持单视频/图片/患者文件夹
`embeddings_cache.pt`	预提取的 Embedding 缓存
`classifier_head.pt`	训练好的分类头权重
`文字表述.txt`	5 类切面的医学文字描述
`.api_key`	DashScope API Key

七、后续计划：患者级多切面聚合

当前每个切面（二腔/三腔/四腔/LV-GLS/RV-GLS）作为独立样本训练，一个患者产生 5 个训练样本。改进方向是将一个患者的全部切面聚合为一个样本。

方案

```
患者 → 二腔.mp4   → API编码 → emb1 (2560维)
     → 三腔.mp4   → API编码 → emb2 (2560维)
     → 四腔.mp4   → API编码 → emb3 (2560维)
     → LV-GLS.jpg → API编码 → emb4 (2560维)
     → RV-GLS.jpg → API编码 → emb5 (2560维)
          ↓
     聚合方式（待实验对比）：
     A) 平均池化:   (emb1+emb2+emb3+emb4+emb5)/5 → 2560维 → 分类器
     B) 拼接:       [emb1,emb2,emb3,emb4,emb5] → 12800维 → 分类器
     C) 最大池化:    max(emb1,...,emb5) → 2560维 → 分类器
     D) 注意力池化:  可学习的加权平均 → 2560维 → 分类器
```

预期收益

- 患者级标签更合理（一个患者要么 HOCM 要么不是，而非每个切面独立判断）
- 多切面信息互补，可能提升分类鲁棒性
- 样本数从 375 降至约 75（患者数），但每个样本特征更丰富

8. OSS URL 直传方案

当前 precompute 使用 base64 Data URI 方式上传视频，存在 Jackson JSON 解析器 28MB 字符串限制，导致部分大视频需压缩。后续计划使用 OSS 签名 URL 方式直传：

```
本地视频 → 上传到 OSS → 获取签名 URL → API 以 HTTPS URL 方式输入
```

已通过分支 `url-upload` 验证可行性：

- OSS bucket: url11 (华北2北京)
- 签名 URL 24小时有效，无需设置公共读
- 3.7MB 视频已成功通过 URL 编码为 2560维 embedding

对比	base64 方式	OSS URL 方式
视频大小限制	~21MB	50MB
是否需要压缩	大视频需压缩	**无需压缩**
请求体积	大（JSON 内含 video）	小（仅 URL 字符串）
额外依赖	无	OSS bucket + oss2 SDK

> 当前 `url-upload` 分支 precompute 正在运行中，完成后可与 v2.5 对比。

八、使用方法

```
# 一键全流程
python train.py --mode all

# 单独推理
python infer.py --video "路径/video.mp4"
python infer.py --image "路径/image.jpg"
python infer.py --dir "路径/患者文件夹/"
```

环境依赖

```
torch, numpy, requests, opencv-python, scikit-learn, tqdm, ffmpeg
```